A cluster of small squares in the top right corner, including solid red, hollow red, and hollow blue squares.

Master en Azure Databricks & Spark para Data Engineers [A-Z]

A small cluster of squares in the bottom left corner, including a hollow red square and a solid red square.

Requisitos

- Conocimientos básicos en SQL



- Conocimientos básicos en Python



- Deseable pero NO necesario conocimientos sobre los fundamentos en la nube.



- Muchas ganas de Aprender.



¿Qué aprenderás en esta Sección?

Funciones de un Data Engineer

Introducción a Azure Databricks

Crear Servicio de Azure Databricks

Guía de la Interfaz de Usuario de Azure Databricks

Arquitectura de Azure Databricks





Funciones de un Data Engineer

Funciones de un Data Engineer



Data Owner

¿Qué hacen?

- Desarrollar y gestionar el sistema operativo
 - Aplicaciones Bancarias
 - Aplicaciones de E-commerce
 - Aplicaciones IoT
 - etc



Data Engineer

¿Qué hacen?

- Recopilar y Transformar Datos
 - Comprobar la Calidad
 - Estandarizar
 - Preparar/Modelar
- Fácil de Consumir



Data Consumers

¿Qué hacen?

- Optimizar
 - Prevención de Fraude
- Crecimiento
 - Recomendaciones
- Monitoreo / Reporte
 - Ventas / Ganancias



Introducción a Azure Databricks



Apache Spark

Apache Spark es un motor de análisis de datos unificado y de alto rendimiento, diseñado para el procesamiento masivo de **Big Data** y **Machine Learning**.



Se desarrolló inicialmente en la Universidad de Berkeley en **2009** y se lanzó al público en **2010** bajo la licencia **BSD**.

En **2013**, fue donado a la Fundación Apache Software, consolidándose rápidamente como una solución innovadora en el ecosistema de big data.

Apache Spark se creó desde cero para subsanar las limitaciones observadas en Apache Hadoop.


Spark proporciona APIs que son notablemente más intuitivas y rápidas

Procesar datos en memoria

Spark se ejecuta en un entorno distribuido

utiliza el mismo motor tanto para el procesamiento por lotes (**batch**) como para el procesamiento de flujos de datos en tiempo real (**streaming**)

Arquitectura Apache Spark



Azure Databricks



Databricks



Clusters

Workspace/
Notebook

SQL Analytics

Delta Lake

Administration
Controls

MLFlow

Databases/
Tables

Optimized
Spark(5x
faster)

Azure Databricks



Clusters

Workspace/
Notebook

SQL Analytics

Delta Lake

Administration
Controls

MLFlow

Databases/
Tables

Optimized
Spark(5x
faster)

Unified Azure Portal

Unified Billing

Azure Entra ID

Storage Account

Event Hub

IoT Hub

Azure Dev Ops

Azure Data Factory

Azure ML


Power BI



Arquitectura de Azure Databricks



Arquitectura de Azure Databricks



¿Qué aprenderás en esta Sección?

Tipos de Clusters

Configuración del Cluster

Crear un Cluster

Precios del Cluster

Cluster Pool

Políticas de Cluster






Tipos de Clusters en Azure Databricks



Tipos de Clusters en Azure Databricks





Tipos de Clusters en Azure Databricks

All Purpose

- Creado manualmente
- Persistente
- Adecuado para cargas de trabajo interactivas
- Compartido entre muchos usuarios
- Caro de ejecutar

Job Cluster

- Creado por Jobs
- Terminado al final del Job
- Apto para cargas de trabajo automatizadas
- Aislado solo para el trabajo
- Más barato de ejecutar



Configuración del Cluster

Configuración del Cluster

Cluster Configuration

Policy

Unrestricted



☒ Multi node ☐ Single node

Access mode

Single user access 

Single user



CRISTIAN DONAYRE



Performance

Databricks runtime version

Runtime: 15.4 LTS (Scala 2.12, Spark 3.5.0)



☒ Use Photon Acceleration 

Worker type

Min workers

Max workers

Standard_D4ds_v5

16 GB Memory, 4 Cores



2

8

☐ Spot instances 

Driver type

Same as worker

16 GB Memory, 4 Cores




☒ Enable autoscaling 

☒ Terminate after minutes of inactivity 

Configuración del Cluster

Single / Multi Node

Multi Node



Single Node



Configuración del Cluster

Single / Multi Node

Access Mode

Single User

Acceso de un Solo Usuario
Soporta Python, SQL, Scala, R

Shared

Acceso de Múltiples Usuarios
Sólo disponible en Premium. Soporta Python, SQL

No Isolation Shared

Acceso de Múltiples Usuarios
Soporta Python, SQL, Scala, R

Custom

Configuración heredada

Configuración del Cluster

Single / Multi Node

Access Mode

Databricks Runtime

Databricks Runtime

Spark

Scala, Java,
Python, R

Ubuntu
Libraries

GPU
Libraries

Delta Lake

Otros Servicios Databricks

Databricks Runtime ML

Todas las Librerías de
Databricks runtime

Librerías Populares de ML(PyTorch,
Keras, TensorFlow, XGBoots, etc)

Photon Runtime

Todas las Librerías de
Databricks runtime

Photon Engine



Configuración del Cluster

Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Termination

- Termina el clúster después de X minutos de inactividad.
- El valor predeterminado para los clústeres de nodo único y estándar es 120 minutos.
- Los usuarios pueden especificar un valor entre 10 y 43200 minutos como duración.



Configuración del Cluster

Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Auto Scaling

- El usuario especifica los nodos de trabajo mínimo y máximo.
- Escala automáticamente entre mínimo y máximo según la carga de trabajo.
- No recomendado para cargas de trabajo de streaming.



Configuración del Cluster

Single / Multi Node

Memoria Optimizada

Access Mode

Computación Optimizada

Databricks Runtime

Almacenamiento Optimizado

Auto Termination

Auto Scaling

Propósito General

Cluster VM Type / Size

GPU Acelerada

Configuración del Cluster

Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy

Cluster Configuration

Policy ⓘ

Unrestricted

☒ Multi node ☐ Single node

Access mode ⓘ

Single user access ⓘ

Single user

CRISTIAN DONAYRE

Performance

Databricks runtime version ⓘ

Runtime: 15.4 LTS (Scala 2.12, Spark 3.5.0)

☒ Use Photon Acceleration ⓘ

Worker type ⓘ

Standard_D4ds_v5

16 GB Memory, 4 Cores

Min workers

2

Max workers

8

☐ Spot instances ⓘ

Driver type

Same as worker

16 GB Memory, 4 Cores

☒ Enable autoscaling ⓘ

☒ Terminate after 120 minutes of inactivity ⓘ

Configuración del Cluster

Single / Multi Node

Access Mode


Databricks runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy



Cluster Configuration

Policy ⓘ
Personal Compute


Single user access ⓘ
CRISTIAN DONAYRE

Performance

Databricks runtime version ⓘ
Runtime: 15.4 LTS ML (Scala 2.12, Spark 3.5.0)

Node type ⓘ
Standard_DS3_v2 14 GB Memory, 4 Cores

☒ Terminate after 4320 minutes of inactivity ⓘ



Cluster Configuration

Policy ⓘ
Power User Compute

Access mode ⓘ Single user access ⓘ
Single user ⓘ CRISTIAN DONAYRE

Performance


Databricks runtime version ⓘ
Runtime: 15.4 LTS ML (Scala 2.12, Spark 3.5.0)

☐ Use Photon Acceleration ⓘ
Photon boosts Apache Spark workloads. Not all ML workloads will see an improvement. [Learn more](#)

Worker type ⓘ Min workers Max workers
Standard_DS3_v2 14 GB Memory, 4 Cores 2 10 ☐ Spot instances ⓘ

Driver type
Same as worker 14 GB Memory, 4 Cores

☒ Terminate after 120 minutes of inactivity ⓘ



Cluster Configuration

Policy ⓘ
Legacy Shared Compute

Performance

Databricks runtime version ⓘ
Runtime: 15.4 LTS (Scala 2.12, Spark 3.5.0)

☒ Use Photon Acceleration ⓘ

Worker type ⓘ Min workers Max workers
Standard_DS4_v2 28 GB Memory, 8 Cores 2 10 ☐ Spot instances ⓘ

Driver type
Same as worker 28 GB Memory, 8 Cores

☐ Terminate after 0 minutes of inactivity ⓘ



Configuración del Cluster

Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy

Simplifica la interfaz de usuario

Permite a los usuarios estándar crear clústeres.




Precios del Cluster en Azure Databricks



Precios del Cluster en Azure Databricks



Databricks Cluster




Tipo de Carga de Trabajo
(All Purpose / Jobs / SQL / Photon)

Nivel (Premium / Standard)

Tipo de VM
(General Purpose / GPU / Optimized)


Plan de Compra
(Pago por uso / Pre-Compra)

Precios del Cluster en Azure Databricks



Una Unidad de Databricks (DBU) es una unidad normalizada de potencia de procesamiento en la plataforma Databricks Lakehouse que se utiliza con fines de medición y fijación de precios.

Precios del Cluster en Azure Databricks





Precios del Cluster en Azure Databricks



Single Node Cluster



Virtual Machine
(VM)

Driver

Summary

1 Driver 14 GB Memory, 4 Cores

Runtime 15.4.x-scala2.12

Standard_DS3_v2 0.75 DBU/h

Carga de Trabajo - All Purpose

Precio por Nivel - Premium

Tipo de VM – General
Purpose Standard_DS3_v2

Plan de Compra - Pago por uso



Precios del Cluster en Azure Databricks



Workload	Standard Tier Prices	Premium Tier Prices
Interactive Serverless Compute	-	\$0.67/DBU-hour**
All-Purpose Compute***	\$0.40/DBU-hour	\$0.55/DBU-hour
Automated Serverless Compute	-	\$0.23/DBU-hour****
Jobs Compute***	\$0.15/DBU-hour	\$0.30/DBU-hour
Jobs Light Compute	\$0.07/DBU-hour	\$0.22/DBU-hour
SQL Compute	-	\$0.22/DBU-hour
SQL Pro Compute	-	\$0.55/DBU-hour
Serverless SQL	-	\$0.70/DBU-hour
Serverless Real-Time Inference	-	\$0.07/DBU-hour
Model Training	-	\$0.65/DBU-hour
Databricks Storage Unit	-	\$0.026/DSU

Precios del Cluster en Azure Databricks



Instance	vCPU(s)	RAM	Temporary storage	Pay as you go	1 year savings plan	3 year savings plan	Spot	Add to estimate
DS1 v2	1	3.5 GiB	7 GiB	\$0.0730/hour	\$0.0504/hour ~31% savings	\$0.0343/hour ~52% savings	\$0.0102/hour ~86% savings	+
DS2 v2	2	7 GiB	14 GiB	\$0.1460/hour	\$0.1007/hour ~31% savings	\$0.0686/hour ~52% savings	\$0.0204/hour ~86% savings	+
DS3 v2	4	14 GiB	28 GiB	\$0.2930/hour	\$0.2022/hour ~31% savings	\$0.1377/hour ~53% savings	\$0.0410/hour ~86% savings	+
DS4 v2	8	28 GiB	56 GiB	\$0.5850/hour	\$0.4037/hour ~30% savings	\$0.2750/hour ~52% savings	\$0.0819/hour ~86% savings	+
DS5 v2	16	56 GiB	112 GiB	\$1.1700/hour	\$0.8073/hour ~30% savings	\$0.5499/hour ~52% savings	\$0.1638/hour ~86% savings	+

Precios del Cluster en Azure Databricks



Nº de DBU

0.75

X

Precio basado en la
carga de trabajo / nivel

0.55

=

Costo DBU

0.4125

Summary

1 Driver 14 GB Memory, 4 Cores

Runtime 15.4.x-scala2.12

Standard_DS3_v2 0.75 DBU/h

1 (Driver)

1

X

Precio de la Maquina
Virtual

0.2930

=

Costo del
Driver Node

0.2930

Nº de
Workers

0

X

Precio de la Maquina
Virtual

=

Costo del
Worker Node

0

=

Costo Total
del Clúster

\$0.7055
por hora



Control de Costos en Azure



Control de Costos en Azure

Estimado de Costo para realizar el curso



Azure Data Lake Storage

Azure Data Factory

Azure Databricks Job Cluster

Azure Databricks Cluster Pool

Azure Databricks All Purpose Cluster

- \$0.706 por hora para un pequeño clúster de un solo nodo en el nivel premium.
- Depende del número de horas de uso.
- Experiencia de otros estudiantes - de 20 a 40 horas para completar el curso.
- Experiencia de *Pago* otros estudiantil: \$15 a \$30.
- Dentro del crédito ofrecido por Suscripción Gratuita.

Control de Costos en Azure



Service	Action to be taken
- Azure Data Lake Storage - Azure Data Factory - Azure Databricks Job Cluster - Azure Databricks Cluster Pool - Azure Databricks All Purpose Cluster	- Ninguno – Costo insignificante - Ninguno - se factura solo por la ejecución del Pipeline. - Ninguno – se destruye una vez que se completa el trabajo. - Eliminar el grupo de clústeres al final de la lección - Establezca la finalización automática en 40 minutos

Establece alertas de presupuesto en tu suscripción.



Cluster Pool



Cluster Pool



Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy

Cluster Pool

Permite crear clusters preconfigurados

- Puede reutilizarse para múltiples trabajos(Jobs).
- Reducción del tiempo necesario para crear nuevos Clusters.
- Mejorar la utilización de los recursos.

Principales ventajas

- Mejora de la eficiencia
- Costes reducidos
- Administración simplificada
- Seguridad mejorada

Cluster Pool



Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy

Cluster Pool

¿Cómo funcionan los cluster pools?

→ Cree un Cluster Pool: Defina la configuración deseada para su grupo de clústeres.

→ Añadir clusters al pool: Asignar clusters al pool.

→ Enviar trabajos al pool: Cuando envías un trabajo, puedes especificar que se ejecute en un clúster del pool.

Cluster Pool



Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy

Cluster Pool

Pool
(instancias inactivas 1 e instancias máximas 2)

VM1

Cluster Pool



Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy

Cluster Pool

Pool
(instancias inactivas 1 e instancias máximas 2)

VM2

Cluster 1

VM1

Cluster Pool



Single / Multi Node

Access Mode

Databricks Runtime

Auto Termination

Auto Scaling

Cluster VM Type / Size

Cluster Policy

Cluster Pool

Pool
(instancias inactivas 1 e instancias máximas 2)

Cluster 1

VM1

Cluster 2

VM2




Políticas de Cluster



Políticas de Cluster



Sólo disponible en el nivel Premium



Ocultar atributos

Valores fijos

Establecer valores por defecto

Interfaz de usuario simple

Mantener el coste bajo

Un tipo de Cluster estandar

Permite al usuario estandar a crear

¿Qué aprenderás en esta Sección?

Introducción a Databricks Notebooks

Comandos Mágicos

Databricks Utilities





Databricks Notebooks





Comandos Mágicos





Databricks Utilities



Databricks Utilities



Las utilidades es una biblioteca de utilidades incorporada en Databricks que facilita la interacción con el entorno de ejecución.

1. credentials

2. data

3. fs

4. jobs

5. library

6. meta

7. notebook

8. secrets

9. widgets

10. preview

¿Qué aprenderás en esta Sección?

Introducción al Acceso a Azure Data Lake Storage

Crear Azure Data Lake Gen2 Storage

Azure Storage Explorer

Acceder a Azure Data Lake Storage
mediante Access Keys

Acceder a Azure Data Lake Storage
mediante Token SAS

Acceder a Azure Data Lake Storage
mediante Service Principal

Autenticación mediante ámbito de clúster


Recomendación de Acceso para el Proyecto
con Data Lake Storage





Accesso a Azure Data Lake Storage


Accesso a Azure Data Lake Storage



Storage Access Keys

Shared Access Signature(SAS Token)

Acceso a Azure Data Lake Storage



Azure



Storage Account



ADLS Gen2



Service Principal




Microsoft
Entra ID

Storage Access Keys

Shared Access Signature(SAS Token)

Service Principal

Acceso a Azure Data Lake Storage



Autenticación de ámbito de sesión



Azure



Storage Account



ADLS Gen2



Service Principal



Microsoft
Entra ID

Storage Access Keys


Shared Access Signature(SAS Token)

Service Principal

Acceso a Azure Data Lake Storage



Databricks



Cluster



Notebook

Autenticación de ámbito de sesión

Autenticación de ámbito de Cluster



Azure



Storage Account



ADLS Gen2



Service Principal



Microsoft
Entra ID

Storage Access Keys

Shared Access Signature(SAS Token)

Service Principal



Databricks

Acceso a Azure Data Lake Storage



Cluster



Notebook



Unity Catalog

Autenticación de ámbito de sesión

Autenticación de ámbito de Cluster

Unity Catalog



Azure



Storage Account



ADLS Gen2



Service Principal



Microsoft
Entra ID

Storage Access Keys

Shared Access Signature(SAS Token)

Service Principal



Crear Azure Data Lake Storage Gen2 (ADLS Gen2)





Azure Storage Explorer





Acceder a Azure Data Lake Gen2 Storage mediante Access Keys



Acceder a Azure Data Lake Gen2 Storage mediante Access Keys



ADLS Gen2

Cada cuenta de almacenamiento contiene 2 Claves

Brinda acceso total a la cuenta de almacenamiento

Las Claves se pueden volver a regenerar



Acceder a Azure Data Lake Gen2 Storage mediante Access Keys



Databricks



Access Key



ADLS Gen2

```
spark.conf.set("fs.azure.account.key.<storage-account>.dfs.core.windows.net", "<access-key>")
```

```
spark.conf.set(
  "fs.azure.account.key.moviehistory.dfs.core.windows.net",
  "jzhPZXN+VBHLxgwBq0ktQ7AeDk0UFPa7qCXfK4roH40lYSI9VpnoNQaCrZ3ZsdBrLi7/I9G9zkdX+AStkr/8Ew==")
```



Acceder a Azure Data Lake Gen2 Storage mediante Access Keys



Databricks



abfs(Azure Blob File System) driver



ADLS Gen2

Optimizado para el análisis de Big Data

Ofrece mayor seguridad

<https://learn.microsoft.com/en-us/azure/storage/blobs/data-lake-storage-abfs-driver>



Acceder a Azure Data Lake Gen2 Storage mediante Access Keys



Databricks



abfs(Azure Blob File System) driver



ADLS Gen2



abfss://data@moviehistory.dfs.core.windows.net/

abfss://data@ moviehistory.dfs.core.windows.net/files/

abfss://data@ moviehistory.dfs.core.windows.net/files/movie.csv



Acceder a Azure Data Lake Gen2 Storage mediante Access Keys



Databricks



abfs(Azure Blob File System) driver



ADLS Gen2

```
spark.conf.set("fs.azure.account.key.<storage-account>.dfs.core.windows.net", "<access-key>")
```

```
dbutils.fs.ls("abfs://<container>@<storage-account>.dfs.core.windows.net")
```



Acceder a Azure Data Lake Storage mediante Token SAS



Acceder a Azure Data Lake Storage mediante Token SAS



ADLS Gen2

Proporciona un acceso detallado al almacenamiento

Restringir el acceso a determinados tipos de recursos y servicios

Permite permisos específicos

Restringir el acceso a un periodo de tiempo específico

Limitar el acceso a una dirección IP específica

Uso de acceso recomendado para clientes externos

<https://learn.microsoft.com/en-us/azure/storage/blobs/data-lake-storage-abfs-driver>



Acceder a Azure Data Lake Gen2 Storage mediante Access Keys



Databricks



Shared Access
Signature(SAS)



ADLS Gen2



```
spark.conf.set("fs.azure.account.auth.type.<storage-account>.dfs.core.windows.net", "SAS")
```

```
spark.conf.set("fs.azure.sas.token.provider.type.<storage-account>.dfs.core.windows.net",  
              "org.apache.hadoop.fs.azurebfs.sas.FixedSASTokenProvider")
```


```
spark.conf.set("fs.azure.sas.fixed.token.<storage-account>.dfs.core.windows.net",  
              [dbutils.secrets.get(scope="<scope>", key=" [ <sas-token-key> ") ] )
```



Acceder a Azure Data Lake Storage mediante el Servicio Principal




Acceder a Azure Data Lake Gen2 Storage mediante Access Keys




Acceder a Azure Data Lake Gen2 Storage mediante Access Keys




Databricks



RBAC



Resource Group




"Registrar la Aplicación" en Azure Entra ID / Server Principal

Generar un secreto(contraseña) para la Aplicación

Configurar Spark con App / Client Id, Directory / Tenant Id & Secret

Asignar el Role "Storage Blob Data Contributor" al Data Lake


"Storage Blob Data Reader"




Autenticación mediante Ámbito de Clúster



Autenticación mediante Ámbito de Clúster





Autenticación mediante Ámbito de Clúster





Recomendación de Acceso para el Proyecto con Data Lake Storage

Recomendación de Acceso para el Proyecto con Data Lake Storage



Acceder a Azure Data Lake Storage
mediante Access Keys

Acceder a Azure Data Lake Storage
mediante Token SAS

Acceder a Azure Data Lake Storage
mediante el Servicio Principal

Autenticación
mediante ámbito de clúster

Seguridad de Acceso a
Azure Data Lake Storage

Montaje de Contenedores
Data Lake en Databricks

¿Qué aprenderás en esta Sección?

Introducción a los Secretos de Seguridad

Crear Azure Key Vault

Crear un Secret Scope

Databricks - Secrets Utility

Notebook - Acceder a Azure Data Lake
usando Secrets en Access Key

Notebook - Acceder a Azure Data Lake
usando Secrets en SAS Token

Notebook - Acceder a Azure Data Lake
usando Service Principal

Cluster - Acceder a Azure Data Lake usando Secrets





Secretos de Seguridad



Secretos de Seguridad



Son una forma segura de almacenar y gestionar información confidencial, como contraseñas, claves de acceso, tokens de autenticación (incluyendo tokens SAS) o cadenas de conexión, evitando que esta información se exponga directamente en el código fuente o los notebooks.

Hasta este punto, hemos gestionado las claves de acceso y secretos manteniéndolos en texto plano dentro de notebooks o configuraciones de clusters en Databricks.

Falta de cifrado

Riesgo de exposición
involuntaria

Auditoría limitada

Incumplimiento
normativo

Secret Scopes en Databricks

Azure Key Vault

Secretos de Seguridad




Secret Scopes en Databricks

- los secretos se almacenan en una base de datos cifrada gestionada por Databricks.
- Los secretos se configuran mediante la CLI de Databricks o la API; no es posible gestionarlos desde la interfaz gráfica.
- Aunque son útiles para ciertos casos, tienen limitaciones en términos de portabilidad y compatibilidad con otros servicios de Azure.

Azure Key Vault

- Almacena y protege información sensible, como contraseñas, cadenas de conexión y claves API.
- Este es el enfoque recomendado cuando se utilizan Databricks en Azure.
- Permite compartir secretos de forma segura entre servicios de Azure y aplicaciones.

Secretos de Seguridad





Crear Azure Key Vault





Crear un Secret Scope



Databricks - Secrets Utility

(dbutils.secrets)



Acceder a Azure Data Lake usando Secrets en Access Key



Acceder a Azure Data Lake usando Secrets en SAS Token



Acceder a Azure Data Lake usando Service Principal



Acceder a Azure Data Lake usando Secrets



¿Qué aprenderás en esta Sección?

Introducción a
Databricks File System(DBFS)

Trabajando con DBFS root






Databricks File System(DBFS)



Databricks File System(DBFS)



DBFS es un sistema de archivos distribuido que actúa como una capa de abstracción para almacenar y acceder a archivos dentro de un entorno de Databricks.



Databricks File System(DBFS)



Customer's Databricks account

Customer's Azure subscription

Azure Databricks Control Plane

Manage workspace notebooks, clusters and jobs

Web application user
SSO authentication with Microsoft Entra ID



REST API
Using Client ID and token



Databricks web application



Notebooks



Jobs and query



Cluster management

Serverless compute plane

Compute resources for serverless SQL warehouses and Model Serving

Classic compute plane (VNet)

Compute resources for data processing with clusters and classic (and pro) SQL warehouses



Root DBFS
(FileStore libraries)

Spark logs

Store job results

Direct access or DBFS mount

Workspace root storage for root DBFS and system data

For new workspaces this is ADLS gen2
Workspaces created before March 6, 2023 use Blob Storage

Customer data in ADLS gen2 or Blob Storage

External data sources

Launch clusters**

Start jobs**

Push/pull table metadata

Push logging datax

Push/pull metadata

Upload files

Get job results, cluster logs and put notebook revisions

**The red arrows from the control plane to the classic compute plane indicate logical requests. For workspaces that enable secure cluster connectivity (also known as No Public IP), those request use a tunnel that is initiated by compute resources in the classic compute plane such as clusters. This architecture allows no public IP addresses for compute resources in the classic compute plane.


¿Qué aprenderás en esta Sección?

Introducción al Montaje(Mount)

Montaje(Mount) en Azure Data Lake Storage Gen2

User Defined Function(UDF) - Python





Montaje(Mount) en Databricks




Montaje(Mount) en Databricks




Customer's Databricks account

Customer's Azure subscription



Montaje(Mount) en Databricks



Beneficios:


Acceda a los datos sin necesidad de credenciales.

Acceda a los archivos utilizando la semántica de archivo en lugar de las URL de almacenamiento (ejem. /mnt/storage)


Almacena archivos en el almacenamiento de objetos (por ejemplo, Azure Blob), para que pueda disfrutar de todas las ventajas de Azure.

Solución recomendada para acceder a Azure Storage hasta la introducción de Unity Catalog (Generalmente disponible a partir de finales de 2022)


Montaje(Mount) en Databricks




Montaje(Mount) en Databricks



Montaje(Mount) en Databricks





Montaje(Mount) en Azure Data Lake Storage Gen2





Python

User Defined Function(UDF)



¿Qué aprenderás en esta Sección?

Explicación sobre el Proyecto “Movie”

Cargar Datos del Proyecto “Movie” al Data Lake


Arquitectura para el desarrollo del Proyecto






Explicación sobre el Proyecto “Movie”

Explicación sobre el Proyecto “Movie”




Explicación sobre el Proyecto “Movie”



<https://www.databasestar.com/sample-database-movies/>

movie	CSV
genre	CSV
language	CSV
country	JSON – Línea única
movie_genre	JSON – Línea única
person	JSON – Línea única
movie_cast	JSON – Línea Anidada
language_role	JSON – Línea Anidada
movie_company	Archivos CSV divididos
production_company	Archivos CSV divididos
production_country	Archivos JSON divididos
movie_languages	Archivos JSON divididos



Cargar Datos del Proyecto “Movie” al Data Lake






Arquitectura para el desarrollo del Proyecto





Arquitectura para el desarrollo del Proyecto





Arquitectura para el desarrollo del Proyecto



<https://learn.microsoft.com/en-us/azure/architecture/browse/?terms=Azure%20Databricks>

¿Qué aprenderás en esta Sección?

Arquitectura del Clúster Spark

Dataframe & Dataframe API en Spark







Arquitectura del Clúster Spark




Arquitectura del Clúster Spark




Arquitectura del Clúster Spark



Arquitectura del Clúster Spark



Arquitectura del Clúster Spark





Dataframe & Dataframe API en Spark



Dataframe

Un DataFrame es una abstracción de datos estructurados en Apache Spark. Se puede imaginar como una tabla en una base de datos relacional o una hoja de cálculo en Excel.

Nº	Película	Recaudación mundial	Taquilla (en EE.UU.)	Taquilla (fuera de EE.UU.)	Presupuesto	Distribuidora(s)	Año de estreno
1	Avatar	2 923 706 026	785 221 649 (26,9%)	2 138 484 377 (73,1%)	246 000 000	20th Century Fox	2009
2	Avengers: Endgame	2 799 439 100	858 373 000 (30,7%)	1 941 066 100 (69,3%)	400 000 000	Walt Disney Studios Motion Pictures	2019
3	Avatar: The Way of Water	2 320 251 738	684 075 767 (29,5%)	1 636 174 514 (70,5%)	356 000 000	Walt Disney Studios Motion Pictures	2022
4	Titanic	2 264 743 305	674 292 608 (29,8%)	1 590 450 697 (70,2%)	200 000 000	20th Century Fox / Paramount Pictures	1997
5	Star Wars: Episodio VII - El despertar de la Fuerza	2 071 310 218	936 662 225 (45,2%)	1 134 647 993 (54,8%)	306 000 000	Walt Disney Studios Motion Pictures	2015
6	Avengers: Infinity War	2 052 415 039	678 815 482 (33,1%)	1 373 599 557 (66,9%)	356 000 000	Walt Disney Studios Motion Pictures	2018
7	Spider-Man: No Way Home	1 921 847 111	814 115 070 (42,4%)	1 107 732 041 (57,6%)	200 000 000	Sony Pictures	2021




Dataframe & Dataframe API en Spark



Dataframe API

DataFrame API es una interfaz de alto nivel que Spark ofrece para trabajar con datos estructurados y semiestructurados.



¿Qué aprenderás en esta Sección?

Explicación sobre la Ingestión de Datos

Archivo "movie" - Requisitos

Archivo "movie" - DataFrame Reader

Archivo "movie" - Schema

Archivo "movie" – Select Columns

Archivo "movie" - WithColumn[s] Renamed

Archivo "movie" - WithColumn[s]

Archivo "movie" - DataFrame Writer

Archivo "language" - Requisitos

Archivo "language" - Solución

Archivo "genre" - Requisitos (Tarea)

Archivo "genre" - Solución (Tarea)

Archivo "movie" - PartitionBy





Explicación Ingestión de Datos



Explicación Ingestión de Datos

Ingesta de los 12 archivos en el Data Lake

Los datos Ingestados deben tener el esquema definido


Los datos introducidos deben tener columnas de auditoría

Los datos ingeridos deben almacenarse en formato columnar (ejem. Parquet)

Debe ser capaz de analizar los datos introducidos mediante SQL.

La lógica de ingestión debe ser capaz de gestionar Data Incremental

Explicación Ingestión de Datos



Data Types

Row

Column

Functions

Window

Grouping


Explicación Ingestión de Datos

File Name	File Type	Assignment / Class Work
movie	CSV	Class Work
language	CSV	Class Work
genre	CSV	Assignment
country	JSON – Línea única	Class Work
person	JSON – Línea única	Class Work
movie_genre	JSON – Línea única	Assignment
movie_cast	JSON – Línea Anidada	Class Work
language_role	JSON – Línea Anidada	Assignment
production_company	Archivos CSV divididos	Class Work
movie_company	Archivos CSV divididos	Assignment
movie_languages	Archivos JSON divididos	Class Work
production_country	Archivos JSON divididos	Assignment



Archivo “movie” - Requisitos


Archivo “movie” - Requisitos





Archivo “language” - Requisitos


Archivo “language” - Requisitos





Archivo “genre” - Requisitos

Archivo “genre” - Requisitos





Archivo “movie” - PartitionBy

Archivo "movie" - PartitionBy



Column Name
movieId
title
budget
homePage (dropped)
overview (dropped)
popularity
yearReleaseDate
releaseDate
revenue
durationTime
movieStatus (dropped)
tagline (dropped)
voteAverage
voteCount

PartitionBy

Column Name	Data Type
movie_id (Renamed)	Integer
title	String
budget	Double
popularity	Double
year_release_date (Renamed)	Integer
release_date (Renamed)	Date
revenue	Double
duration_time (Renamed)	Integer
vote_average (Renamed)	Double
vote_count (Renamed)	Integer
ingestion_date (new)	Timestamp
environment (new)	String

¿Qué aprenderás en esta Sección?

Archivo "country" - Requisitos

Archivo "country" - Read Data

Archivo "country" - Transform & Write Data

Archivo "person" - Requisitos

Archivo "person" - Solución

Archivo "movie_genre" - Requisitos (Tarea)

Archivo "movie_genre" - Solución (Tarea)

Archivo "movie_cast" - Requisitos

Archivo "movie_cast" - Solución

Archivo "language_role" - Requisitos (Tarea)


Archivo "language_role" - Solución (Tarea)





Archivo “country” - Requisitos


Archivo “country” - Requisitos





Archivo “person” - Requisitos


Archivo “person” - Requisitos





Archivo “movie_genre” - Requisitos


Archivo “movie_genre” - Requisitos





Archivo “movie_cast” - Requisitos


Archivo “movie_cast” - Requisitos





Archivo “language_role” - Requisitos

Archivo “language_role” - Requisitos



¿Qué aprenderás en esta Sección?

Archivo “production_company” - Requisitos

Archivo “production_company” - Solución

Archivo “movie_company” - Requisitos (Tarea)

Archivo “movie_company” - Solución (Tarea)

Archivo “movie_languages” - Requisitos

Archivo “movie_languages” - Solución

Archivo “production_country” - Requisitos (Tarea)

Archivo “production_country” - Solución (Tarea)






Archivos “production_company” - Requisitos




Archivo “production_company” - Requisitos





Archivos “movie_company” - Requisitos


Archivo “movie_company” - Requisitos





Archivos “movie_languages” - Requisitos


Archivo “movie_languages” - Requisitos





Archivos “production_country” - Requisitos

Archivo “production_country” - Requisitos



¿Qué aprenderás en esta Sección?

Reutilizar código de otro Notebook

Pasar Parámetros al Notebook

Notebook Workflows

Databricks Jobs





Reutilizar código de otro Notebook (%run)





Pasar Parámetros al Notebook (widgets)





Notebook Workflows





Databricks Jobs



¿Qué aprenderás en esta Sección?

Transformación “Filter”

Transformación “Join” - “Inner Join”

Transformación “Join” - “Outer Join”


Transformación “Join” - “Semi, Anti & Cross Join”

Ejercicio Join - Requisitos

Ejercicio Join - Solución

Ejercicio Join - Requisitos (Tarea)

Ejercicio Join - Solución (Tarea)





Transformación “Filter”





Transformación “Join” - “Inner Join”

Transformación “Join” - “Inner Join”


Una transformación de inner join en Spark combina dos conjuntos de datos basándose en una condición de igualdad entre las columnas especificadas en ambas tablas. Solo las filas que cumplen con esta condición de emparejamiento en ambas tablas se incluirán en el resultado final.

nombre_id	nombre
1	Alice
2	Bob
3	Charlie

edad_id	edad
1	25
2	30
4	40

nombre_id	nombre	edad_id	edad
1	Alice	1	25
2	Bob	2	30

Transformación "Join" - "Inner Join"





Transformación “Join” - “Outer Join”

Transformación “Join” - “Outer Join”

Una transformación outer join en Spark combina dos DataFrames o tablas y devuelve todas las filas de ambas, incluso si no hay coincidencias entre ellas. Si una fila no tiene coincidencias en la otro Dataframe o tabla, las columnas correspondientes tendrán valores **NULL**.

Tipos de “Outer Join”:

left

right

full

semi

anti

cross

leftouter

rightouter

fullouter

leftsemi

leftanti

left_outer

right_outer

full_outer

left_semi

left_anti

Transformación “Join” - “Outer Join”

Left Join:

- Devuelve todas las filas de la tabla izquierda.
- Las filas de la tabla derecha que no coinciden con la izquierda tendrán valores **NULL**.

nombre_id	nombre
1	Alice
2	Bob
3	Charlie

edad_id	edad
1	25
2	30
4	40

nombre_id	nombre	edad_id	edad
1	Alice	1	25
2	Bob	2	30
3	Charlie	null	null

Transformación “Join” - “Outer Join”

Right Join:

- Devuelve todas las filas de la tabla derecha.
- Las filas de la tabla izquierda que no coinciden con la derecha tendrán valores **NULL**.

nombre_id	nombre
1	Alice
2	Bob
3	Charlie

edad_id	edad
1	25
2	30
4	40

nombre_id	nombre	edad_id	edad
1	Alice	1	25
2	Bob	2	30
null	null	4	40

Transformación “Join” - “Outer Join”

Full Join:

- Devuelve todas las filas de ambas tablas, incluyendo las que no tienen coincidencias.
- Las filas no coincidentes tienen valores **NULL** en las columnas de la otra tabla.

nombre_id	nombre
1	Alice
2	Bob
3	Charlie

edad_id	edad
1	25
2	30
4	40

nombre_id	nombre	edad_id	edad
1	Alice	1	25
2	Bob	2	30
3	Charlie	null	null
null	null	4	40



Transformación “Join” “Semi, Anti & Cross Join”

Transformación “Join” “Semi, Anti & Cross Join”

Las transformaciones “semi, anti, y cross join” son herramientas para combinar o filtrar conjuntos de datos en función de diferentes lógicas. Cada uno tiene características únicas que los hacen útiles en diferentes escenarios.

Tipos de “Outer Join”:

left

right

full

semi

anti

cross

leftouter

rightouter

fullouter

leftsemi

leftanti

left_outer

right_outer

full_outer

left_semi

left_anti

Transformación “Join”

“Semi, Anti & Cross Join”

Semi Join:

Un semi join devuelve solo las filas del DataFrame izquierdo que tienen coincidencias en el DataFrame derecho, pero no devuelve las columnas del derecho. Es una forma de filtrar el izquierdo basado en el derecho.

nombre_id	nombre
1	Alice
2	Bob
3	Charlie

edad_id	edad
1	25
2	30
4	40



nombre_id	nombre
1	Alice
2	Bob

Transformación “Join” “Semi, Anti & Cross Join”

Anti Join:

Un anti join devuelve solo las filas del DataFrame izquierdo que **no tienen coincidencias** en el DataFrame derecho

nombre_id	nombre
1	Alice
2	Bob
3	Charlie

edad_id	edad
1	25
2	30
4	40



nombre_id	nombre
3	Charlie

Transformación “Join”

“Semi, Anti & Cross Join”

Cross Join:

La transformación cross join genera el **producto cartesiano** de dos DataFrames, combinando cada fila del DataFrame izquierdo con cada fila del derecho.

nombre_id	nombre
1	Alice
2	Bob
3	Charlie

edad_id	edad
1	25
2	30
4	40



nombre_id	nombre	edad_id	edad
1	Alice	1	25
1	Alice	2	30
1	Alice	4	40
2	Bob	1	25
2	Bob	2	30
2	Bob	4	40
3	Charlie	1	25
3	Charlie	2	30
3	Charlie	4	40



Ejercicio “Join” - “Requisitos”

Ejercicio “Join” - “Requisitos”



Se requiere obtener información de las “películas” del año 2000 en adelante ordenado de manera descendente por la fecha de lanzamiento, se debe considerar su respectivo “genero” y el “idioma” que se encuentra dicha película.

- De la película se requiere mostrar el “título, el tiempo de duración, la fecha de lanzamiento y el voto promedio”.
- De idioma se requiere mostrar el “nombre del idioma”.
- Del genero mostrar el “nombre del género”.

Ejercicio "Join" - "Requisitos"


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



Ejercicio "Join" - "Requisitos"


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



results_movie_genre_language

Column Name	Source
title	movies
duration_time	movies
release_date	movies
vote_average	movies
language_name	languages
genre_name	genres
created_date	current_timestamp



Ejercicio “Join” - “Requisitos” (Tarea)

Ejercicio “Join” - “Requisitos” (Tarea)



Se requiere obtener información de las “películas”, el “País” donde se realizó la grabación y cual fue la “productora” encargada de realizarlo.

La información debe ser a partir del año 2010 en adelante de la fecha de lanzamiento, ordenado de manera ascendente por el “título” de la película.

- De la película se requiere mostrar el “título”, “el presupuesto”, “los ingresos obtenidos”, “tiempo de duración” y la “fecha de lanzamiento”.
- De País se requiere mostrar el “nombre del país”.
- De la “Productora” se requiere el “nombre de la productora”.

Ejercicio "Join" - "Requisitos" (Tarea)


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



Ejercicio "Join" - "Requisitos" (Tarea)


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



results_country_prod_company

Column Name	Source
title	movies
budget	movies
revenue	movies
duration_time	movies
release_date	movies
country_name	countries
company_name	productions_companies
created_date	current_timestamp

¿Qué aprenderás en esta Sección?

Funciones Simples de Agregación

Group By

Window Functions

Ejercicio "Aggregation" - Requisitos

Ejercicio Aggregation - Solución

Ejercicio Aggregation - Requisitos (Tarea)

Ejercicio Aggregation - Solución (Tarea)





Funciones Simples de Agregación



Group By



Window Functions



Ejercicio “Aggregation” - Requisitos

Ejercicio “Aggregation” - Requisitos



Se requiere obtener información sobre el “total del presupuesto” y “total de ingresos” de las “películas” donde el “año de la fecha de lanzamiento” debe ser mayor o igual a 2015, también debe estar agrupado por el “año de la fecha de lanzamiento” y el “genero” al que pertenece cada película.

También se requiere realizar un ranking ordenado de manera ascendente por el “total del presupuesto” y “total de ingresos” particionado por el “Año de la fecha de lanzamiento”.

Ejercicio "Aggregation" - Requisitos


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



Ejercicio "Aggregation" - Requisitos


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



results_group_movie_genre

Column Name	Source
year_release_date	movies
budget	movies
revenue	movies
genre_name	genres
rank	Window Functions



Ejercicio Aggregation - Requisitos (Tarea)

Ejercicio Aggregation - Requisitos (Tarea)



Se requiere obtener información sobre el “total del presupuesto” y “total de ingresos” de las “películas” donde el “año de la fecha de lanzamiento” debe ser mayor o igual a 2015, también debe estar agrupado por el “año de la fecha de lanzamiento” y el “país” en donde se realizó la película.

También se requiere realizar un ranking ordenado de manera “descendente” por el “total del presupuesto” y “total de ingresos” particionado por el “Año de la fecha de lanzamiento”.

Ejercicio Aggregation - Requisitos (Tarea)


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



Ejercicio Aggregation - Requisitos (Tarea)


Layer Silver
Parquet

Read Data

Transform Data

Write Data

Layer Gold
Parquet



results_group_movie_country

Column Name	Source
year_release_date	movies
budget	movies
revenue	movies
country_name	countries
rank	Window Functions

¿Qué aprenderás en esta Sección?

Spark SQL - Introducción

Base de datos (Database)

Tablas Gestionadas (Managed Tables)

Tablas externas (External Tables)

Vistas (Views)

Proyecto "Movie" - Requisitos SQL

Crear Tabla - Archivo de Origen CSV

Crear Tabla - Archivo de Origen JSON

Crear Tabla - Múltiples archivos de Origen

Crear Tabla - Capa "Silver"

Crear Tabla - Capa "Gold" (Tarea)






Spark SQL - Introducción


Spark SQL - Introducción

Hive Meta Store




Spark SQL - Introducción

Database / Table / View





Arquitectura para el desarrollo del Proyecto



¿Qué aprenderás en esta Sección?

SQL DML(Data Manipulation Language)

SQL Escalar Functions(Funciones Escalares)

SQL Aggregate Functions(Funciones de Agregación)

SQL Window Functions(Funciones de Ventana)

SQL Joins(Uniones)



¿Qué aprenderás en esta Sección?

Crear la Tabla "results_movie"

Análisis - Presupuesto e Ingreso por País

Análisis - Presupuesto e Ingreso por Productora(Tarea)

Visualización - Presupuesto e Ingreso por País

Visualización - Presupuesto e Ingreso por Productora(Tarea)





Vizualicación

¿Qué aprenderás en esta Sección?

Patrones de Diseño de Carga de Datos

Explicación - Proyecto "Movie"

Configurar y Cargar Datos - Proyecto "Movie"

Actualización - Carga Completa de Datos

Carga Incremental - UDF

Carga Incremental - Notebook Workflows

Carga Incremental - Results (Parte 1)

Carga Incremental - Results (Parte 2)





Patrones de Diseño de Carga de Datos



Patrones de Diseño de Carga de Datos


Tipos de Carga de Datos

Carga Completa
(Full Load)

Carga Incremental
(Incremental Load)

Patrones de Diseño de Carga de Datos


Tipos de Carga de Datos





Arquitectura para el desarrollo del Proyecto


Carga Completa – Día 1





Arquitectura para el desarrollo del Proyecto


Carga Completa – Día 2





Arquitectura para el desarrollo del Proyecto

Carga Completa – Día 3



Patrones de Diseño de Carga de Datos

Carga incremental

Día 1

Movie1

Día 2

Movie2

Día 3

Movie3


Día 4

Movie4



Arquitectura para el desarrollo del Proyecto


Carga incremental – Día 1





Arquitectura para el desarrollo del Proyecto


Carga incremental – Día 2





Arquitectura para el desarrollo del Proyecto

Carga incremental – Día 3





Explicación - Proyecto “Movie”

Explicación - Proyecto “movie”

Carga de Datos

Semana 1

Movie “...”

Movie “...”

Movie “...”

....

Movie “...”

Semana 2

Movie “...”

Movie “...”

....

Movie “...”

Semana 3

Movie “...”

....

Movie “...”

□ Carga Completa

Carga Incremental

Carga Incremental

Explicación - Proyecto “movie”

Carga de Datos – Solución 1

Semana 1

Movie “...”

Movie “...”

Movie “...”

....

Movie “...”

Semana 2

Movie “...”

Movie “...”

....

Movie “...”

Semana 3

Movie “...”

....

Movie “...”

□ Carga Completa

Carga Incremental

Carga Incremental

Explicación - Proyecto “movie”

Carga de Datos – Solución 2

Semana 1

Movie “...”

Movie “...”

Movie “...”

....

Movie “...”

Semana 2

Movie “...”

Movie “...”

....

Movie “...”

Semana 3

Movie “...”

....

Movie “...”

□ Carga Incremental

Carga Incremental

Carga Incremental

Explicación - Proyecto “movie”



File Name	File Type
language	Datos Completos
genre	Datos Completos
country	Datos Completos
language_role	Datos Completos
movie	Datos Particionados
person	Datos Particionados
movie_genre	Datos Particionados
movie_cast	Datos Particionados
production_company	Datos Particionados
movie_company	Datos Particionados
movie_languages	Datos Particionados
production_country	Datos Particionados


Explicación - Proyecto “movie”



File Name	File Type
language	Datos Completos
genre	Datos Completos
country	Datos Completos
language_role	Datos Completos
movie	Datos Particionados
person	Datos Particionados
movie_genre	Datos Particionados
movie_cast	Datos Particionados
production_company	Datos Particionados
movie_company	Datos Particionados
movie_languages	Datos Particionados
production_country	Datos Particionados


Explicación - Proyecto “movie”

Solución Actual



Explicación - Proyecto "movie"

Solución Actual





Actualización - Carga Completa de Datos

Actualización - Carga Completa de Datos



File Name	File Type
language	Datos Completos
genre	Datos Completos
country	Datos Completos
language_role	Datos Completos
movie	Datos Particionados
person	Datos Particionados
movie_genre	Datos Particionados
movie_cast	Datos Particionados
production_company	Datos Particionados
movie_company	Datos Particionados
movie_language	Datos Particionados
production_country	Datos Particionados



Carga Incremental

Carga Incremental




File Name	File Type
language	Datos Completos
genre	Datos Completos
country	Datos Completos
language_role	Datos Completos
movie	Datos Particionados
person	Datos Particionados
movie_genre	Datos Particionados
movie_cast	Datos Particionados
production_company	Datos Particionados
movie_company	Datos Particionados
movie_language	Datos Particionados
production_country	Datos Particionados



Carga Incremental - Results

Carga Incremental - Results



¿Qué aprenderás en esta Sección?

Introducción a Delta Lake

Delta Lake y Data Lakehouse

Read y Write en Delta Lake

Update y Delete en Delta Lake

Merge/Upsert en Delta Lake

History, Time Travel y Vacuum

Transaction Log en Delta Lake

Convertir formato "Parquet" a "Delta"



¿Qué aprenderás en esta Sección?

Data Ingestion - Archivo “language”

Data Ingestion - Archivo “movie”

Carga Incremental - User Defined Function(UDF)

Data Ingestion - Notebooks Restantes

Data Transformation - Todos los Notebooks

Data Transformation - Notebook SQL






Delta Lake


Delta Lake

Data Warehouse



Delta Lake

Data Warehouse



Falta de soporte para datos no estructurados

Se tarda más en incorporar nuevos datos

Formatos de datos propios


Escalabilidad

Almacenamiento de datos costoso

Falta de soporte para cargas de trabajo ML/AI


Delta Lake

Data Lake



Delta Lake

Data Lake



No soporta transacciones ACID

Las Jobs fallidas dejan archivos parciales

Lecturas inconsistentes

Incapaz de manejar correcciones de datos

No se puede restaurar ningún dato

Sin historial ni control de versiones

Bajo rendimiento

Poco soporte BI

Configuración compleja

Arquitectura Lambda para cargas de trabajo de streaming



Delta Lake y Data Lakehouse



Delta Lake y Data Lakehouse

Delta Lake

Delta Lake es una tecnología clave dentro de Databricks que actúa como una capa de almacenamiento optimizada, proporcionando confiabilidad y eficiencia en entornos de datos masivos.

Data Lakehouse


La arquitectura Lakehouse es una evolución que combina lo mejor de los data lakes y los data warehouses. Permite una plataforma unificada para el almacenamiento y análisis de datos, eliminando la necesidad de mantener sistemas separados.

Delta Lake y la arquitectura Lakehouse en Databricks han transformado la forma en que las organizaciones almacenan y analizan sus datos. Juntos, ofrecen una plataforma unificada, confiable y escalable, capaz de manejar las necesidades modernas de análisis en tiempo real, machine learning y big data, simplificando operaciones y reduciendo costos.

En Databricks, Delta Lake es el núcleo que hace posible la arquitectura Lakehouse.


Delta Lake y Data Lakehouse

Data Lakehouse



Delta Lake y Data Lakehouse

Data Lakehouse



Maneja todo tipo de datos

Almacenamiento barato en la nube

Utiliza formato de código abierto

Soporte para todo tipo de cargas de trabajo

Capacidad para usar herramientas de BI

Soporte ACID

Historia y control de versiones

Mejor rendimiento


Arquitectura simple

Delta Lake y Data Lakehouse


Data Warehouse



Data Lake




Data Lakehouse



Delta Lake y Data Lakehouse

Delta Lake



¿Qué aprenderás en esta Sección?

Introducción - Azure Data Factory

Crear el servicio de Azure Data Factory

Componentes de Azure Data Factory

Crear Pipeline - Ingestar Notebook Movie

Debug Pipeline

Agregar Pipeline - Ingestar los otros Notebooks

Agregar validación al Pipeline

Enviar notificación Email desde el Pipeline

Crear Pipeline - Notebooks de Transformación

Crear Trigger






Introducción - Azure Data Factory



Introducción - Azure Data Factory

¿Qué es Azure Data Factory?




Azure Data Factory es un servicio en la nube administrado creado para estos complejos proyectos híbridos de extracción, transformación y carga (ETL) ó extracción, carga y transformación (ELT) e integración de datos.




Introducción - Azure Data Factory

El problema de los datos




Introducción - Azure Data Factory

El problema de los datos




Introducción - Azure Data Factory

El problema de los datos




Introducción - Azure Data Factory

El problema de los datos




Introducción - Azure Data Factory

El problema de los datos



Introducción - Azure Data Factory

¿Qué es Azure Data Factory?



Servicio totalmente administrado

Serverless

Servicio de integración de datos


Servicio de transformación de datos

Servicio de orquestación de datos

Azure Data Factory es un servicio en la nube administrado creado para estos complejos proyectos híbridos de extracción, transformación y carga (ETL) ó extracción, carga y transformación (ELT) e integración de datos.

Introducción - Azure Data Factory

¿Qué NO es Azure Data Factory?



Herramienta de Migración de Datos

Servicio de Streaming de Datos

Adecuado para la Transformación de Datos Complejos

Servicio de almacenamiento de datos

Azure Data Factory es un servicio en la nube administrado creado para estos complejos proyectos híbridos de extracción, transformación y carga (ETL) ó extracción, carga y transformación (ELT) e integración de datos.



Componentes de Azure Data Factory



Componentes de Azure Data Factory

Trigger

Pipeline

Activity

Activity

Dataset

Linked Service

Linked Service

Storage

ADLS

SQL
Database

Compute

Azure
Databricks

¿Qué aprenderás en esta Sección?

Introducción a Unity Catalog

Configuración de Unity Catalog

Crear Unity Catalog Metastore


Crear Cluster para Unity Catalog

Modelo de Objetos de Unity Catalog

Introducción a External Data con Data Lake

Crear "Storage Credential"

Crear "External Location"





Introducción a Unity Catalog

Unity Catalog



Unity Catalog

Unity Catalog es un **sistema unificado** de administración y gobernanza de datos en todo un **Data Lakehouse** o una infraestructura de almacenamiento en la nube.

Gobernanza de Datos


Es el proceso de gestión de la disponibilidad, usabilidad, integridad y seguridad de los datos presentes en una empresa.

Controla el acceso de los usuarios a los datos



Garantiza que los datos son de confianza y no se utilizan indebidamente

Ayuda a aplicar normativas sobre privacidad de los datos

Gobernanza de Datos



Sin Unity Catalog



Azure Data Lake Storage (ADLS Gen2)

Sin Unity Catalog



Databricks
Workspace 1

User Management

Metastore

Compute



Databricks
Workspace 1

User Management

Metastore

Compute



Databricks
Workspace 1

User Management

Metastore

Compute

Con Unity Catalog

Sin Unity Catalog



Databricks
Workspace 1

User Management

Metastore

Compute



Databricks
Workspace 1

User Management

Metastore

Compute

Databricks Account

Con Unity Catalog

Databricks Unity Catalog

User Management

Metastore



Databricks
Workspace 1

Compute




Databricks
Workspace 2


Compute

Databricks Account

Unity Catalog




Unity Catalog






Configuración de Unity Catalog


Configuración de Unity Catalog




Configuración de Unity Catalog




Configuración de Unity Catalog




Configuración de Unity Catalog



Configuración de Unity Catalog



Configuración de Unity Catalog



Crear Azure Databricks Workspace

Crear Azure Data Lake Gen 2

Crear Access Connector for Databricks

Añadir role "Storage Blob Data Contributor"

Crear Unity Catalog Metastore

Habilitar Databricks Workspace para Unity Catalog




Crear Unity Catalog Metastore

Requisitos Previos

Crear Unity Catalog Metastore


Requisitos Previos





Crear Unity Catalog Metastore

Crear Unity Catalog Metastore





Crear Cluster para Unity Catalog



Modelo de Objetos de Unity Catalog

Modelo de Objetos de Unity Catalog

Metastore

Contenedor de nivel superior


Sólo uno por región

Emparejar por defecto con ADLS Storage

Modelo de Objetos de Unity Catalog



Modelo de Objetos de Unity Catalog




Contenedor de siguiente del Catalog


Schemas y Database son los mismos

Usar Schema en lugar de Database


Modelo de Objetos de Unity Catalog




Modelo de Objetos de Unity Catalog




Modelo de Objetos de Unity Catalog




Modelo de Objetos de Unity Catalog




Modelo de Objetos de Unity Catalog




Modelo de Objetos de Unity Catalog



Modelo de Objetos de Unity Catalog



Modelo de Objetos de Unity Catalog






External Data con Data Lake


External Data con Data Lake

Configuración Unity Catalog




External Data con Data Lake

Acceso a ubicaciones externas



External Data con Data Lake

Objetos de Unity Catalog



External Data con Data Lake

Storage Credential / External Locations



El Storage Credential es un objeto de credencial que se crea dentro de Unity Catalog

Se utiliza el “nombre del usuario” para acceder al almacenamiento ADLS

Creado mediante Identidad Gestionada/
Servicio Principal

Es un Objeto almacenado de forma centralizada en el metastore


Combina la ruta ADLS con la credencial de almacenamiento Cloud Object Store

Esta sujeto a Políticas de Control de Acceso de Unity Catalog

Se le pueden asignar Políticas de Control de Acceso


External Data con Data Lake

Acceso a Ubicaciones Externas




External Data con Data Lake

Acceso a Ubicaciones Externas




External Data con Data Lake

Acceso a Ubicaciones Externas



External Data con Data Lake

Acceso a Ubicaciones Externas



Crear "Access Connector"

Crear "Azure Data Lake Storage"

Asignar el Role "Storage Blob Data Contributor"


Crear "Storage Credential"

Crear "External Location"



Crear "Storage Credential"


Crear "Storage Credential"





Crear “External Location”


Crear "External Location"






Descripción del Proyecto

Descripción del Proyecto



Descripción del Proyecto



Crear Storage Container

Crear External Location

Crear Catalog & Schema

Crear Tabla Bronze(External)


Crear Tabla Silver(Managed)

Crear Tabla Gold(Managed)

Crear Databricks Workflow

Descripción del Proyecto

Mini Proyecto – Crear External Location



Crear Storage Container

Crear External Location

Crear Catalog & Schema

Crear Tabla Bronze(External)


Crear Tabla Silver(Managed)

Crear Tabla Gold(Managed)

Crear Databricks Workflow

Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema



Crear Storage Container

Crear External Location

Crear Catalog & Schema

Crear Tabla Bronze(External)


Crear Tabla Silver(Managed)

Crear Tabla Gold(Managed)

Crear Databricks Workflow

Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema




```

CREATE TABLE IF NOT EXISTS telco_dev.bronze.clientes(
  clienteId INT,
  nombre STRING,
  paterno STRING,
  materno STRING,
  documentoIdentidad STRING,
  email STRING,
  direccion STRING
)
USING CSV
OPTIONS (path "abfss://bronze@sadatabricksext.dfs.core.windows.net/clientes.csv")
  
```

Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema




```

CREATE TABLE IF NOT EXISTS telco_dev.silver.clientes
AS
SELECT
  clienteId AS cliente_id,
  CONCAT(nombre, ' ', paterno, ' ', materno) AS nombre_completo,
  documentoIdentidad AS documento_identidad,
  telefono,
  email,
  direccion,
  current_timestamp() AS ingestion_date
FROM telco_dev.bronze.clientes;
  
```


Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema



Managed Location
(Obligatorio)

3



Default Storage
(ADLS Gen2 Container)

Managed Location
(Opcional)

2



Default Storage
(ADLS Gen2 Container)

Managed Location
(Opcional)


1



Default Storage
(ADLS Gen2 Container)


Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema




Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema



Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema




Default Storage
(ADLS Gen2 Container)



Default Storage
(ADLS Gen2 Container)

Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema



Crear Storage Container

Crear External Location

Crear Catalog & Schema

Crear Tabla Bronze(External)


Crear Tabla Silver(Managed)

Crear Tabla Gold(Managed)

Crear Databricks Workflow

Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema



Crear Storage Container

Crear External Location

Crear Catalog & Schema

Crear Tabla Bronze(External)


Crear Tabla Silver(Managed)

Crear Tabla Gold(Managed)

Crear Databricks Workflow

Descripción del Proyecto

Mini Proyecto – Crear Catalog & Schema



Crear Storage Container

Crear External Location

Crear Catalog & Schema

Crear Tabla Bronze(External)

Crear Tabla Silver(Managed)

Crear Tabla Gold(Managed)

Crear Databricks Workflow



felicitaciones!




¿Cuál es el siguiente paso?

DISEÑO DE BASES DE DATOS RELACIONALES



SQL SERVER INTEGRATION SERVICES DESDE CERO



¿Cuál es el siguiente paso?

**AZURE DATA
FACTORY(ADF)**



**APRENDE TABLEAU DESDE
CERO HASTA EXPERTO**



 datademy.com

felicitaciones!

